ENFOQUE

La IA generativa: amenazas y oportunidades

La IA generativa (las herramientas que producen texto, imágenes, sonido o vídeo a demanda, como ChatGPT) concentra hoy buena parte de la preocupación por la desinformación. El balance disponible conduce a una posición con dos vertientes:

- **Hasta ahora, la conmoción anunciada no se ha producido.** Se temía que la IA inclinara el resultado de las elecciones de 2024-2025; los estudios no encuentran rastro alguno de ello en los resultados.
- **La amenaza sigue siendo seria de cara al futuro.** Las herramientas avanzan con rapidez, en particular la llamada IA «agéntica»: programas capaces de actuar de forma autónoma, que podrían dirigir «enjambres» de miles de cuentas falsas coordinadas que imitan a seres humanos (Schroeder et al., 2026).

Este enfoque distingue tres tipos de efectos:

- **Los efectos directos**, es decir, la capacidad de la IA para hacer cambiar el voto, se han sobrestimado.
- **Los efectos indirectos**, más difusos, son más perniciosos: erosionan la confianza.
- **El efecto sistémico** es el de mayor calado: la IA debilita la financiación de los medios que producen información de calidad.

A la inversa, la IA ofrece herramientas útiles para cada uno de los cuatro pilares de acción pública que se presentan en la nota.

UNA TECNOLOGÍA *PHARMAKON*

En Platón (Fedro), la palabra griega pharmakon designa a la vez el remedio y el veneno. La IA generativa es un buen ejemplo de ello. Lo que la hace peligrosa, su capacidad para producir de forma masiva argumentos fluidos y adaptados a cada persona, es también lo que puede hacerla útil para mejorar la calidad de la información.

La cuestión, por tanto, no es estar a favor o en contra de la IA, sino saber qué salvaguardas inclinan la balanza del lado del remedio: la regulación, la transparencia, la decisión final en manos de seres humanos y la inversión pública en los usos beneficiosos.

Conviene, además, precisar el alcance: el debate no debe limitarse a la IA *generativa*.

- **Otra forma de IA lleva una década en funcionamiento.** Se trata de los sistemas de recomendación, que deciden lo que aparece en un flujo de noticias.
- **Están configurados para maximizar la interacción** (clics, contenidos compartidos, tiempo de permanencia), y está documentado un vínculo entre este objetivo y la amplificación de los contenidos polarizadores.
- **Ambos problemas son indisociables.** Un contenido generado por IA solo tiene impacto si se ve y, por tanto, en la medida en que estos algoritmos lo promocionan.

PARA PROFUNDIZAR

El grueso de la argumentación sobre las amenazas se apoya en la síntesis de Felix M. Simon y Sacha Altay: *Don't Panic (Yet): Assessing the Evidence and Discourse Around Generative AI and Elections*, Knight First Amendment Institute (Columbia University), 2025.

Otras dos síntesis de referencia:

- El metaanálisis del IPIE (Panel Internacional sobre el Entorno Informativo), que reúne 24 publicaciones y cerca de 34 000 participantes: A. Herasimenka et al., *Confronting Misinformation Produced with Generative AI: A Meta-Analysis of Experimental Scientific Evidence*, IPIE, 2026.
- Una revisión de la literatura sobre el papel de la IA generativa en la producción, la detección, la corrección y los efectos de la desinformación: S. Park y X. Nan,

Generative AI and misinformation: a scoping review, *AI & Society*, 2025.

Las amenazas

1. Un impacto directo sobrestimado

El temor más extendido es el siguiente: puesto que la IA abarata drásticamente el coste de producir información falsa, inundará el espacio público e inclinará el resultado de las elecciones. El ciclo electoral de 2024-2025 no lo ha confirmado. Y no es una cuestión de suerte: hay razones de fondo.

Elecciones de 2024-2025: ninguna prueba de impacto en los resultados

Los contenidos generados por IA siguieron siendo marginales:

- **En la India**, en torno al **1 %** de los mensajes virales analizados en WhatsApp (Garimella y Chauchard, 2024).
- **En el Reino Unido**, solo se registraron **16** casos virales de desinformación fabricada con IA (Stockwell et al., 2024).

La razón es estructural:

- **Una atención saturada.** La atención del público es limitada y ya está saturada de contenidos.
- **Una desinformación «impulsada por la demanda».** La gente consume contenidos falsos porque busca lo que refuerza sus opiniones, no porque aumente la oferta.

Producir más información falsa no genera, por tanto, más lectores: un contenido más no es sino una gota en el océano (Simon y Altay, 2025).

Calidad: basta un montaje burdo

Los *cheapfakes*, o «falsificaciones baratas» (una imagen sacada de contexto, un montaje rudimentario, una simple afirmación falsa), se utilizaron **7 veces** más que la IA (Kapoor y Narayanan, 2024).

- **Son «lo bastante buenos» para su función.** El público se adhiere al relato que el contenido refuerza, no a la calidad de su factura.
- **Lo que más cuenta es la fuente.** Un vídeo mediocre difundido por un gran medio pesa más que un ultrafalso o *deepfake* (vídeo falso realista creado con IA) perfecto difundido por una cuenta anónima. Ahora bien, la IA puede mejorar la calidad de un contenido, pero muy difícilmente la credibilidad de quien lo difunde (Harris, 2021).

- **Dos usos exigen vigilancia:** el audio (la clonación de la voz de una figura pública) y los *deepnudes*, imágenes falsas de desnudos que se dirigen en particular contra las mujeres políticas.

Personalización: la microsegmentación aporta poco

La microsegmentación consiste en dirigir a cada votante un mensaje adaptado a su perfil.

- **Un mito heredado de Cambridge Analytica.** Atribuirle un gran poder prolonga ese mito: esta empresa, que en 2014 había obtenido, sin que estos lo supieran, los datos de hasta 87 millones de usuarios de Facebook, afirmaba influir en las votaciones de 2016 mediante mensajes adaptados a la personalidad de cada cual, pero sus efectos reales nunca llegaron a demostrarse.
- **La IA no cambia esta constatación.** Los mensajes políticos redactados por GPT-4 son ciertamente persuasivos, pero segmentarlos con precisión no los hace significativamente más eficaces que un mensaje genérico (Hackenburg y Margetts, 2024). En 19 modelos de IA, la personalización solo añade de media **0,4 puntos** al efecto persuasivo (Hackenburg et al., 2025).
- **Una práctica marginal.** En el gasto real de las campañas, la microsegmentación precisa sigue siendo, por lo demás, marginal (Votta et al., 2024).

Capacidad persuasiva: tanto como un ser humano, pero a gran escala

Es el único ámbito realmente preocupante. En un diálogo, un agente conversacional responde a las objeciones de su interlocutor y ajusta sus argumentos. Resultado:

- **Más persuasiva que un mensaje estático.** Una conversación con la IA sería aproximadamente un **50 %** más persuasiva que un mensaje estático, leído una sola vez y sin intercambio (Hackenburg et al., 2025).
- **E incluso más que los seres humanos.** Un diálogo personalizado puede llegar a convencer más que debatientes humanos (Salvi et al., 2025).

Su fuerza reside en el número de argumentos precisos que esgrime, no en la cantidad de contenidos producidos. De ahí el matiz que conviene retener: convencer a todo el mundo con un mismo mensaje sigue siendo difícil, pero la IA

hace concebible una persuasión «cara a cara», llevada a cabo simultáneamente con millones de personas.

2. Unos impactos indirectos perniciosos

Los efectos más inquietantes no pasan por la persuasión directa, sino por el deterioro de la confianza y de los referentes comunes.

Dividendo del mentiroso

Cuanto más sabe todo el mundo que un contenido puede fabricarse, más fácil resulta recusar una prueba auténtica: «este vídeo no es real, es IA». El mentiroso obtiene así un beneficio, un «dividendo», de la mera existencia de las falsificaciones. Algunos estudios muestran que esta estrategia puede funcionar (Schiff, Schiff y Bueno, 2025). Pero su éxito depende menos de la tecnología que de la confianza que el público ya deposita en quien lo niega. Prospera, por tanto, allí donde la desconfianza hacia las instituciones es elevada.

Falsas señales sociales

Perfiles falsos creados en serie, personajes ficticios animados de forma coordinada, sitios de noticias totalmente automatizados: el objetivo no es persuadir, sino hacer pasar una opinión marginal por mayoritaria.

- **La eficacia directa de estas operaciones es escasa.** La Internet Research Agency, la «fábrica de troles» rusa, no tuvo ningún efecto medible en las elecciones estadounidenses de 2016 (Eady et al., 2023).
- **La amenaza se sitúa más bien en el futuro**: la **contaminación de los datos de entrenamiento** de los futuros modelos de IA, que aprenden a partir de los textos disponibles en la web. Es lo que intentó la red prorrusa Pravda al replicar sus contenidos en unos 150 sitios, para que los asistentes de IA acabaran reproduciendo sus relatos (VIGINUM, 2025; NewsGuard, 2025).

Relaciones entre seres humanos e IA

Los asistentes de IA están entrenados para agradar a su usuario y a menudo se perciben como personas. Se convierten así en confidentes, e incluso en compañeros. Para la mayoría del público, el efecto sigue siendo limitado: solo el 27 % confía en la IA para informarse sobre política (Ejaz et al., 2024). Pero el riesgo se concentra en las **personas aisladas**, precisamente aquellas a las que la soledad hace más receptivas a las teorías de la conspiración (Bierwiaczonek et al., 2024).

Declive de la confianza

A fuerza de sospechar que todo puede ser sintético, el público corre el riesgo de dudar también de la información exacta.

- **Una duda que se extiende.** En un experimento, los participantes expuestos a un ultrafalso conceden después menos crédito a *todos* los medios, incluso una vez revelada la falsificación (Weikmann, Greber y Nikolaou, 2024).
- **Un público ya demasiado desconfiado.** Peca más por exceso de duda que por credulidad: rechaza una información verdadera con más frecuencia de la que acepta una falsa (Pfänder y Altay, 2025).
- **Un alarmismo que agrava el problema.** Los discursos alarmistas sobre la desinformación, incluidos los relativos a la IA, acentúan esta tendencia (Hoes et al., 2024; Jungherr y Rauchfleisch, 2024).

3. Un impacto sistémico: la información de calidad, sin financiación

Es el riesgo menos espectacular y el más serio. Ya está en marcha, sus efectos se acumulan y afecta a los medios de información, de los que dependen todas las demás defensas.

El mecanismo es sencillo. Un motor de búsqueda devolvía una lista de enlaces a fuentes; un asistente de IA proporciona directamente una **respuesta única**. Es la llamada búsqueda «sin clic»: el usuario obtiene la información sin visitar el sitio del medio que la ha producido. Ahora bien, ese medio vivía de esa visita (publicidad, suscripciones).

−33 % de visitas procedentes de Google hacia 2500 sitios de noticias en un año; los asistentes de IA les remiten menos del 1 % de las visitas (Chartbeat, 2026).

60 % de los sitios de información fiables bloquean los rastreadores de IA, frente al **9 %** de los sitios de desinformación. Por consiguiente, las IA corren el riesgo de aprender en mayor medida de fuentes poco fiables (Steinacker-Olsztyn et al., 2025).

Este choque golpea a un sector ya debilitado.

- **Unos ingresos publicitarios que se escapan.** Entre 2012 y 2022, la proporción de los ingresos publicitarios que corresponde a los medios que producen la información pasó del 65 % al 40 % (DGMIC-Arcom, 2024); el resto va sobre todo a las plataformas digitales, que no producen información por sí mismas.
- **Un valor captado sin contrapartida.** La IA capta el valor de la información sin pagar su producción.
- **Un círculo vicioso.** Se alimenta, por tanto, de un periodismo al que contribuye a dejar sin financiación y, a la larga, degrada la calidad de sus propias respuestas.

El problema no es que lo falso suplante a lo verdadero, sino que lo verdadero se empobrece.

Fuentes principales: VIGINUM, 2025 · Alan Turing Institute, 2024-2025 · Hackenburg et al., 2025 · Schiff, Schiff y Bueno, *APSR*, 2025 · Hoes et al., 2024 · Chartbeat, 2026 · Steinacker-Olsztyn et al., 2025 · Simon y Altay, 2025 · G. Darcy, comparecencia n.º 48 ante la CIANum, 2026.

Las oportunidades, pilar por pilar

Las capacidades que hacen inquietante a la IA (comprender, sintetizar, argumentar, traducir a gran escala) también pueden servir a cada uno de los cuatro pilares de la nota.

PILAR 1 — SECAR LA OFERTA DE DESINFORMACIÓN

1. **Monitorización en tiempo real:** detectar y señalar los contenidos sospechosos. Sobre todo, la IA puede detectar *señales de coordinación*, es decir, los indicios de que una campaña está orquestada: cuentas que publican en el mismo momento, cuentas antiguas reutilizadas, redes de sitios automatizados. Ello evita tener que juzgar la veracidad de cada contenido. Salvaguarda: un error de detección que hiciera pasar indebidamente una movilización ciudadana espontánea por una operación coordinada tendría un elevado coste democrático.
2. **Verificación de datos multilingüe:** verificar contenidos en varias lenguas y seguir la circulación de un mismo relato de un país a otro, allí donde las redacciones carecen de medios.

PILAR 2 — ACTUAR SOBRE LAS CAUSAS INMEDIATAS DE LA ADHESIÓN

3. **Diálogos contra las teorías de la conspiración:** personas que se adherían a una teoría de la conspiración dialogaron con una IA que les oponía contraargumentos personalizados y fundamentados. Su adhesión disminuyó en torno a un **20 %**, y el efecto seguía siendo medible dos meses después (Costello, Pennycook y Rand, 2024). No se trata de un truco de magia: la persuasión funciona porque los hechos están del lado de la IA, y lo que convence es la calidad de los argumentos.
4. **Ayuda a la verificación:** localizar y evaluar las fuentes. La herramienta SIDE detecta en Wikipedia las referencias que no respaldan realmente la afirmación citada y propone otras mejores. En las referencias consideradas más dudosas, los evaluadores humanos prefirieron sus propuestas en el **70 %** de los casos (Petroni et al., 2023).
5. **Tutores y juegos:** entrenarse para reconocer las técnicas de manipulación. Es el principio de la «inoculación», o *prebunking*: como con una vacuna, se expone de antemano a las personas a una versión atenuada de una manipulación para que después sepan reconocerla. Su principal limitación es que el efecto se erosiona con el tiempo si no se mantiene mediante recordatorios. Unos ejercicios adaptados al nivel de cada persona y repetidos en el tiempo, que la IA hace posibles, responden a esta limitación.

PILAR 3 — ACTUAR SOBRE LAS CAUSAS PROFUNDAS DE LA ADHESIÓN

6. **Mediación deliberativa:** ayudar a un grupo en desacuerdo a encontrar un terreno común. En un experimento, una IA mediadora redactó síntesis de la discusión consideradas más claras y más justas que las de mediadores humanos (Tessler et al., 2024). Herramientas comparables se utilizan ya en consultas ciudadanas a gran escala: recogen las opiniones de miles de participantes y ponen de relieve los puntos de acuerdo (Polis en Taiwán, Remesh para las Naciones Unidas).

7. **Debate sereno:** sintetizar puntos de vista opuestos y reformular. Un asistente que sugiere en tiempo real formulaciones más respetuosas mejora la calidad percibida de una discusión política en línea (Argyle et al., 2023). Los participantes no cambian de opinión en el fondo: la herramienta actúa sobre la forma del intercambio, y eso basta para reducir la hostilidad.

PILAR 4 — APOYAR LA INFORMACIÓN DE CALIDAD

8. **Traducción:** en la India, en 2024, la IA tradujo la información electoral a más de veinte lenguas y llegó así a votantes mal atendidos por los medios tradicionales (Shukla y Schneier, 2024). Fue incluso su uso principal durante la campaña.

9. **Accesibilidad:** resumir, explicar, leer en voz alta, para hacer accesible la información fiable a las personas que leen poco o siguen poco la actualidad.

10. **Redacciones mejor equipadas:** transcripción de entrevistas, monitorización, búsqueda en archivos. La IA libera así tiempo para el trabajo periodístico, en particular en la prensa local, donde los equipos son reducidos.

LO ESENCIAL

La fuerza persuasiva de la IA es **neutral respecto a la verdad**: convence tanto de lo verdadero como de lo falso. Los diálogos que reducen la adhesión a las teorías de la conspiración también pueden instaurarla cuando se diseñan con ese fin (Costello et al., 2026). La IA no es una fuerza impersonal: son empresas y Estados quienes toman decisiones de diseño. De ahí tres orientaciones:

- **Regular a través de los actores:** imponer la transparencia (saber que se está hablando con una IA), prohibir la persuasión encubierta, someter a evaluación independiente la capacidad persuasiva de los modelos y limitar la complacencia de los compañeros de IA, es decir, su tendencia a halagar al usuario y a darle la razón.
- **Proteger la información de calidad:** obligar a los proveedores de IA a compartir el valor con los editores de prensa, como ya hacen los «derechos afines», que obligan a las plataformas a remunerar la reutilización de los artículos; y exigir que las respuestas de los asistentes remitan a sus fuentes.
- **Apoyar los usos beneficiosos con salvaguardas,** sin ceder al discurso alarmista: como se ha visto, este discurso tiene un coste cuantificado para la confianza del público.

Fuentes principales: T. Nygren et al., *Behavioral Science & Policy*, 2026 · Costello, Pennycook y Rand, *Science*, 2024 · Tessler et al., *Science*, 2024 · Petroni et al., 2023 · Argyle et al., 2023 · Shukla y Schneier, 2024 · Simon y Altay, 2025 · G. Darcy, comparecencia n.º 48 ante la CIANum, 2026.

Contact : gregoire.darcy@protonmail.com

Institut Jean-Nicod — ENS-PSL · 2026

Esta es una traducción automática del original francés. Realizada con ayuda de inteligencia artificial, puede contener errores.