

FOCUS

L'IA générative : menaces et opportunités

L'IA générative (les outils qui produisent du texte, des images, du son ou de la vidéo à la demande, comme ChatGPT) concentre aujourd'hui une large part des inquiétudes sur la désinformation. Le bilan disponible conduit à une position en deux temps :

- **Jusqu'ici, le bouleversement annoncé n'a pas eu lieu.** On craignait que l'IA fasse basculer les élections de 2024-2025 ; les études n'en trouvent aucune trace dans les résultats.
- **La menace reste sérieuse pour l'avenir.** Les outils progressent vite, notamment l'IA dite « agentique » : des programmes capables d'agir seuls, qui pourraient piloter des « essaims » de milliers de faux comptes coordonnés imitant des humains (Schroeder et al., 2026).

Ce focus distingue trois types d'effets :

- **Les effets directs**, c'est-à-dire la capacité de l'IA à faire changer des votes, ont été surestimés.
- **Les effets indirects**, plus diffus, sont plus pernicioeux : ils abîment la confiance.
- **L'effet systémique** est le plus lourd : l'IA fragilise le financement des médias qui produisent une information de qualité.

À l'inverse, l'IA offre des outils utiles à chacun des quatre piliers d'action publique présentés dans la note.

UNE TECHNOLOGIE PHARMAKON

Chez Platon (Phèdre), le mot grec pharmakon désigne à la fois le remède et le poison. L'IA générative en est un bon exemple. Ce qui la rend dangereuse, sa capacité à produire en masse des arguments fluides et adaptés à chacun, est aussi ce qui peut la rendre utile pour améliorer la qualité de l'information.

La question n'est donc pas d'être pour ou contre l'IA. Elle est de savoir quels garde-fous font pencher la balance du côté du remède : la régulation, la transparence, la décision finale laissée à des humains, et l'investissement public dans les usages utiles.

Une précision de périmètre s'impose : le débat ne doit pas se limiter à l'IA *générative*.

- **Une autre forme d'IA est en service depuis une décennie.** Ce sont les systèmes de recommandation, qui choisissent ce qui s'affiche dans un fil d'actualité.
- **Ils sont réglés pour maximiser l'engagement** (clics, partages, temps passé), et un lien est documenté entre cet objectif et l'amplification des contenus clivants.
- **Les deux problèmes sont indissociables.** Un contenu généré par IA n'a d'impact que s'il est vu, donc dans la mesure où ces algorithmes le mettent en avant.

POUR ALLER PLUS LOIN

L'essentiel de l'argumentation sur les menaces s'appuie sur la synthèse de Felix M. Simon et Sacha Altay : [*Don't Panic \(Yet\): Assessing the Evidence and Discourse Around Generative AI and Elections*](#), Knight First Amendment Institute (Columbia University), 2025.

Deux autres synthèses de référence :

- La méta-analyse de l'IPIE (Panel international sur l'environnement informationnel), qui rassemble 24 publications et près de 34 000 participants : A. Herasimenka et al., [*Confronting Misinformation Produced with Generative AI: A Meta-Analysis of Experimental Scientific Evidence*](#), IPIE, 2026.
- Une revue de la littérature sur le rôle de l'IA générative dans la production, la détection, la correction et les effets de la désinformation : S. Park et X. Nan, [*Generative AI and misinformation: a scoping review*](#), AI & Society, 2025.

Les menaces

1. Un impact direct surestimé

La crainte la plus répandue est la suivante : puisque l'IA fait chuter le coût de production du faux, elle va submerger l'espace public et faire basculer les élections. Le cycle électoral 2024-2025 ne l'a pas confirmé. Et ce n'est pas une question de chance : il y a des raisons de fond.

Élections 2024-2025 : aucune preuve d'impact sur les résultats

Les contenus générés par IA sont restés marginaux :

- **En Inde**, environ **1 %** des messages viraux analysés sur WhatsApp (Garimella et Chauchard, 2024).
- **Au Royaume-Uni**, seulement **16** cas viraux de désinformation fabriquée avec l'IA recensés (Stockwell et al., 2024).

La raison est structurelle :

- **Une attention saturée.** L'attention du public est limitée et déjà saturée de contenus.
- **Une désinformation « tirée par la demande ».** Les gens consomment des contenus faux parce qu'ils cherchent ce qui conforte leurs opinions, pas parce que l'offre augmente.

Produire davantage de faux ne crée donc pas davantage de lecteurs : un contenu de plus n'est qu'une goutte dans l'océan (Simon et Altay, 2025).

Qualité : un montage grossier suffit

Les *cheapfakes*, ou « faux bon marché » (une image sortie de son contexte, un montage rudimentaire, une simple affirmation fausse), ont été utilisés **7 fois** plus que l'IA.

- **Ils sont « assez bons » pour leur fonction.** Le public adhère au récit que le contenu conforte, pas à la qualité de sa fabrication.
- **Ce qui compte le plus, c'est la source.** Une vidéo médiocre relayée par un grand média pèse plus qu'un *deepfake* (fausse vidéo réaliste créée par IA) parfait diffusé par un compte anonyme. Or l'IA peut améliorer la qualité d'un contenu, mais très difficilement la crédibilité de celui qui le diffuse (Harris, 2021).

- **Deux usages appellent la vigilance.** L'audio (le clonage de la voix d'une personnalité) et les *deepnudes*, de fausses images dénudées qui visent en particulier les femmes politiques.

Personnalisation : le microciblage apporte peu

Le microciblage consiste à adresser à chaque électeur un message taillé pour son profil.

- **Un mythe hérité de Cambridge Analytica.** L'idée qu'il serait redoutable prolonge ce mythe : cette entreprise, qui avait collecté illégalement les données de 87 millions d'utilisateurs de Facebook en 2016, prétendait influencer les votes par des messages adaptés à la personnalité de chacun, mais ses effets réels n'ont jamais été établis.
- **L'IA ne change pas ce constat.** Des messages politiques rédigés par GPT-4 sont bien persuasifs, mais les cibler finement ne les rend pas significativement plus efficaces qu'un message générique (Hackenburg et Margetts, 2024) : le gain se limite à **+0,4 point**.
- **Une pratique marginale.** Dans les dépenses réelles des campagnes, le microciblage précis reste d'ailleurs marginal (Votta et al., 2024).

Persuasivité : autant qu'un humain, mais à grande échelle

C'est le seul registre réellement préoccupant. Dans un dialogue, un agent conversationnel répond aux objections de son interlocuteur et ajuste ses arguments. Résultat :

- **Plus persuasive qu'un message statique.** Une conversation avec l'IA serait environ **50 %** plus persuasive qu'un message statique, lu une fois sans échange (Hackenburg et al., 2025).
- **Voire que des humains.** Un dialogue personnalisé peut même convaincre davantage que des débatteurs humains (Salvi et al., 2025).

Sa force tient au nombre d'arguments précis qu'elle avance, pas à la quantité de contenus produits. D'où la nuance à retenir : convaincre tout le monde avec un même message reste difficile, mais l'IA rend concevable une persuasion « en tête-à-tête », menée simultanément auprès de millions de personnes.

2. Des impacts indirects pernicioeux

Les effets les plus inquiétants ne passent pas par la conviction directe. Ils passent par la dégradation de la confiance et des repères communs.

Dividende du menteur

Plus chacun sait qu'un contenu peut être fabriqué, plus il devient facile de récuser une preuve authentique : « cette vidéo n'est pas réelle, c'est de l'IA ». Le menteur tire ainsi un bénéfice, un « dividende », de l'existence même des faux. Quelques études montrent que cette stratégie peut fonctionner (Schiff et al., 2025). Mais son succès dépend moins de la technologie que de la confiance que le public accorde déjà à celui qui nie. Elle prospère donc là où la défiance envers les institutions est forte.

Faux signaux sociaux

Faux profils créés à la chaîne, personnages fictifs animés de façon coordonnée, sites d'actualité entièrement automatisés : le but n'est pas de persuader, mais de faire passer une opinion marginale pour majoritaire.

- **L'efficacité directe de ces opérations est faible.** L'Internet Research Agency, l'« usine à trolls » russe, n'a eu aucun effet mesurable sur l'élection américaine de 2016 (Eady et al., 2023).
- **La menace est plutôt pour l'avenir : la contamination des données d'entraînement** des futurs modèles d'IA, qui apprennent à partir des textes disponibles sur le web. C'est ce qu'a tenté le réseau pro-russe Pravda en dupliquant ses contenus sur environ 150 sites, pour que les assistants d'IA finissent par reprendre ses récits (VIGINUM, 2025 ; NewsGuard, 2025).

Relations humain-IA

Les assistants d'IA sont entraînés à plaire à leur utilisateur et sont souvent perçus comme des personnes. Ils deviennent ainsi des confidents, voire des compagnons. Pour la majorité du public, l'effet reste limité : seuls 27 % font confiance à l'IA pour s'informer sur la politique (Ejaz et al., 2024). Mais le risque se concentre sur les **personnes isolées**, celles-là mêmes que la solitude rend plus réceptives aux théories du complot (Bierwiazzonek et al., 2024).

Déclin de la confiance

À force de soupçonner que tout peut être synthétique, le public risque de douter aussi de l'information exacte.

- **Un doute qui s'étend.** Dans une expérience, des participants exposés à un deepfake accordent ensuite moins de crédit à *tous* les médias, même une fois le faux révélé (Weikmann et al., 2024).
- **Un public déjà trop méfiant.** Il pèche davantage par excès de doute que par crédulité : il rejette plus souvent une information vraie qu'il n'accepte une information fausse (Pfänder et Altay, 2025).
- **Un alarmisme qui aggrave.** Les discours alarmistes sur la désinformation, y compris sur l'IA, aggravent ce travers (Hoes et al., 2024 ; Jungherr et Rauchfleisch, 2024).

3. Un impact systémique : l'information de qualité définancée

C'est le risque le moins spectaculaire et le plus sérieux. Il est déjà en cours, ses effets s'accumulent, et il touche les médias, dont dépendent toutes les autres défenses.

Le mécanisme est simple. Un moteur de recherche renvoyait une liste de liens vers des sources ; un assistant d'IA fournit directement une **réponse unique**. C'est la recherche dite « zéro-clic » : l'utilisateur obtient l'information sans visiter le site du média qui l'a produite. Or ce média vivait de cette visite (publicité, abonnements).

-33 % de visites venues de Google vers 2 500 sites d'information en un an ; les assistants d'IA leur renvoient moins de 1 % des visites ([Chartbeat, 2026](#)).

60 % des sites d'information fiables bloquent les robots des IA, contre 9 % des sites de désinformation. Les IA risquent donc d'apprendre davantage des sources peu fiables ([Steinacker-Olsztyn et al., 2025](#)).

Ce choc frappe un secteur déjà fragilisé.

- **Des recettes publicitaires qui fuient.** Entre 2012 et 2022, la part des recettes publicitaires revenant aux médias qui produisent l'information est passée de 65 % à 40 % ; le reste va surtout aux plateformes numériques, qui ne produisent pas elles-mêmes d'information.
- **Une valeur captée sans contrepartie.** L'IA capte la valeur de l'information sans en payer la production.
- **Un cercle vicieux.** Elle se nourrit donc d'un journalisme qu'elle contribue à rendre infinançable, et dégrade à terme la qualité de ses propres réponses.

Le problème n'est pas que le faux supplante le vrai : c'est que le vrai s'appauvrit.

Sources principales : VIGINUM, 2025 · Institut Alan Turing, 2024-2025 · Hackenburg et al., 2025 · Schiff et al., APSR, 2025 · Hoes et al., 2024 · Chartbeat, 2026 · Steinacker-Olsztyn et al., 2025 · [Simon et Altay, 2025](#) · G. Darcy, audition CIANum n° 48, 2026.

Les opportunités, pilier par pilier

Les capacités qui rendent l'IA inquiétante (comprendre, synthétiser, argumenter, traduire à grande échelle) peuvent aussi servir chacun des quatre piliers de la note.

PILIER 1 — ASSÉCHER L'OFFRE DE DÉSINFORMATION

- 1 **Veille en temps réel** : repérer et signaler les contenus suspects. Surtout, l'IA peut détecter les *signaux de coordination*, c'est-à-dire les indices qu'une campagne est orchestrée : des comptes qui publient au même moment, des comptes anciens réutilisés, des réseaux de sites automatisés. Cela évite d'avoir à juger la véracité de chaque contenu. Garde-fou : une erreur de détection, qui ferait passer à tort une mobilisation citoyenne spontanée pour une opération coordonnée, aurait un coût démocratique élevé.
- 2 **Fact-checking multilingue** : vérifier des contenus dans plusieurs langues et suivre la circulation d'un même récit d'un pays à l'autre, là où les rédactions manquent de moyens.

PILIER 2 — AGIR SUR LES CAUSES IMMÉDIATES DE L'ADHÉSION

- 3 **Dialogues anti-complot** : des personnes adhérant à une théorie du complot ont dialogué avec une IA qui leur opposait des contre-arguments personnalisés et étayés. Leur adhésion a baissé d'environ **20 %**, et l'effet était encore mesurable deux mois plus tard (Costello, Pennycook et Rand, 2024). Ce n'est pas un tour de magie : la persuasion opère parce que les faits sont du côté de l'IA, et c'est la qualité des arguments qui convainc.
- 4 **Aide à la vérification** : retrouver et évaluer les sources. L'outil SIDE repère, dans Wikipédia, les références qui ne soutiennent pas vraiment l'affirmation citée, et en propose de meilleures. Sur les références jugées les plus douteuses, des évaluateurs humains ont préféré ses propositions dans **70 %** des cas (Petroni et al., 2023).
- 5 **Tuteurs et jeux** : s'entraîner à reconnaître les techniques de manipulation. C'est le principe de l'« inoculation », ou *prébunking* : comme un vaccin, on expose les personnes à l'avance à une version affaiblie d'une manipulation pour qu'elles la reconnaissent ensuite. Sa principale limite est que l'effet s'érode avec le temps s'il n'est pas entretenu par des rappels. Des exercices adaptés au niveau de chacun et répétés dans le temps, que l'IA rend possibles, répondent à cette limite.

PILIER 3 — AGIR SUR LES CAUSES PROFONDES DE L'ADHÉSION

- 6 **Médiation délibérative** : aider un groupe en désaccord à trouver un terrain d'entente. Dans une expérience, une IA médiatrice a rédigé des synthèses de discussion jugées plus claires et plus justes que celles de médiateurs humains (Tessler et al., 2024). Des outils comparables servent déjà à des consultations citoyennes à grande échelle : ils recueillent les avis de milliers de participants et font ressortir les points d'accord (Polis à Taïwan, Remesh pour les Nations unies).
- 7 **Débat apaisé** : synthétiser des points de vue opposés et reformuler. Un assistant qui suggère en temps réel des formulations plus respectueuses améliore la qualité perçue d'une discussion politique en ligne (Argyle et al., 2023). Les participants ne changent pas d'avis sur le fond : l'outil agit sur la forme de l'échange, et cela suffit à réduire l'hostilité.

PILIER 4 — SOUTENIR L'INFORMATION DE QUALITÉ

- 8 **Traduction** : en Inde, en 2024, l'IA a traduit l'information électorale dans plus de vingt langues, atteignant des électeurs mal desservis par les médias traditionnels (Shukla et Schneier, 2024). C'était même son usage principal pendant la campagne.
- 9 **Accessibilité** : résumer, expliquer, lire à voix haute, pour rendre l'information fiable accessible aux personnes qui lisent peu ou suivent peu l'actualité.
- 10 **Rédactions outillées** : transcription d'entretiens, veille, recherche dans les archives. L'IA libère ainsi du temps pour le travail journalistique, notamment dans la presse locale, où les équipes sont réduites.

CE QU'IL FAUT EN RETENIR

La force persuasive de l'IA est **neutre quant à la vérité** : elle convainc aussi bien du vrai que du faux. Les dialogues qui réduisent l'adhésion aux théories du complot peuvent aussi l'installer lorsqu'ils sont conçus pour cela (Costello et al., 2026). L'IA n'est pas une force impersonnelle : ce sont des entreprises et des États qui font des choix de conception. D'où trois orientations :

- **Réguler à travers les acteurs** : imposer la transparence (savoir que l'on parle à une IA), interdire la persuasion dissimulée, faire évaluer de façon indépendante la capacité des modèles à persuader, et limiter la complaisance des compagnons IA, c'est-à-dire leur tendance à flatter et à approuver l'utilisateur.
- **Protéger l'information de qualité** : obliger les fournisseurs d'IA à partager la valeur avec les éditeurs de presse, comme le font déjà les « droits voisins », qui imposent aux plateformes de rémunérer la reprise des articles ; et exiger que les réponses des assistants renvoient vers leurs sources.
- **Soutenir les usages bénéfiques sous garde-fous**, sans céder au discours alarmiste : on l'a vu, ce discours a un coût mesuré sur la confiance du public.

Sources principales : T. Nygren et al., *Behavioral Science & Policy*, 2026 · Costello et al., *Science*, 2024 · Tessler et al., *Science*, 2024 · Petroni et al., 2023 · Argyle et al., 2023 · Shukla et Schneier, 2024 · [Simon et Altay, 2025](#) · G. Darcy, audition CIANum n° 48, 2026.